Revue de littérature : Détection des tumeurs cérébrales par apprentissage automatique et *deep learning*

26 avril 2026

1 Introduction

La détection précoce des tumeurs cérébrales constitue un enjeu majeur en imagerie médicale, car elle influence directement le diagnostic, l'orientation thérapeutique et le pronostic du patient. L'IRM (Imagerie par Résonance Magnétique) est aujourd'hui l'un des examens de référence pour l'analyse des lésions intracrâniennes, en raison de son excellent contraste des tissus mous et de sa capacité à visualiser des anomalies structurelles fines [1]. Dans ce contexte, les approches de *machine learning* et, plus récemment, de *deep learning* ont suscité un intérêt croissant pour automatiser la détection, la classification et parfois la segmentation des tumeurs cérébrales à partir d'images IRM [2, 3].

L'objectif de cette revue est de présenter un aperçu de l'état de la recherche sur la détection du cancer du cerveau à l'aide de modèles ML/DL, avec un accent particulier sur les réseaux de neurones convolutifs (CNN). Les travaux récents montrent que ces modèles atteignent des performances élevées sur des jeux de données standards [2, 4], mais leur transfert en pratique clinique reste encore limité par plusieurs facteurs, notamment la taille réduite des bases d'images, la variabilité entre centres hospitaliers et le risque de surapprentissage [5, 6].

2 Des méthodes classiques au *deep learning*

Les premières approches de détection des tumeurs cérébrales reposaient sur des méthodes d'apprentissage automatique classiques combinant prétraitement d'image, extraction manuelle de caractéristiques et classification à l'aide de modèles comme SVM, k-means, *random forest* ou k-nearest neighbors [7, 5]. Ces méthodes ont ouvert la voie à l'automatisation, mais elles dépendaient fortement de la qualité des descripteurs extraits manuellement, ce qui limitait leur robustesse face à la diversité des images IRM.

L'essor du *deep learning* a profondément modifié ce champ de recherche. Contrairement aux approches traditionnelles, les réseaux de neurones convolutifs apprennent automatiquement des représentations hiérarchiques à partir des images brutes [3]. Cette capacité a permis de réduire la dépendance à l'ingénierie de caractéristiques et d'améliorer les performances de classification et de détection. Les revues récentes soulignent que les CNN sont devenus la famille de modèles dominante pour l'analyse des tumeurs cérébrales en IRM, en particulier pour la classification binaire ou multi-classe et, dans une moindre mesure, pour la segmentation [3, 8].

3 Les principales tâches étudiées

La littérature sur les tumeurs cérébrales par *deep learning* se répartit généralement en trois tâches principales : la détection, la segmentation, la classification et la prédiction. La classification vise à déterminer si une image contient une tumeur et, parfois, à identifier son type. La détection consiste à localiser la région tumorale dans l'image. La segmentation cherche à délimiter précisément la tumeur pixel par pixel, ce qui est particulièrement utile pour l'évaluation volumétrique et le suivi clinique [6, 1].

Dans les articles récents, la classification est la tâche la plus fréquente, car elle est plus simple à mettre en œuvre et nécessite souvent moins d'annotation que la segmentation [3]. Des architectures comme ResNet, VGG, DenseNet, MobileNet ou EfficientNet sont souvent utilisées en transfert d'apprentissage, parfois adaptées à des bases de données relativement petites [2, 4]. Les travaux expérimentaux que nous avons sélectionnés montrent cette tendance, avec des modèles de type MobileNetV3 ou YOLOv7 intégrant des mécanismes d'attention ou des stratégies de *transfer learning* pour améliorer la précision [2, 9].

4 Apports des CNN et du *transfer learning*

Les CNN ont apporté un progrès important dans la détection des tumeurs cérébrales, car ils sont capables de capturer automatiquement des motifs complexes liés aux textures, aux contours et aux formes présentes dans les IRM [5, 1]. Les revues récentes indiquent que les modèles profonds surpassent souvent les approches classiques sur les *benchmarks* standards, surtout lorsque les images ont été correctement prétraitées et que des stratégies d'augmentation de données ont été appliquées [3, 8].

Un autre levier important est le *transfer learning*. Dans ce cadre, des réseaux préentraînés sur de grandes bases d'images naturelles sont réutilisés puis ajustés à des images médicales [2, 4]. Cette stratégie est particulièrement utile en imagerie médicale, où les bases annotées sont souvent limitées [3]. Plusieurs travaux récents montrent que le *transfer learning* permet d'obtenir de bonnes performances avec moins de données qu'un entraînement entièrement réalisé depuis zéro [9, 1]. Cela explique pourquoi de nombreux articles récents comparent plusieurs architectures préentraînées plutôt que de proposer un nouveau réseau entièrement conçu pour le problème.

5 Vers la détection et la localisation

Au-delà de la classification, une tendance importante dans la littérature récente est l'usage de modèles de détection d'objets, notamment les variantes de YOLO, pour repérer automatiquement les zones tumorales dans les IRM [2]. Cette approche présente l'avantage de combiner rapidité et localisation, ce qui peut être intéressant dans des contextes d'aide au diagnostic. L'article que nous avons choisi sur YOLOv7 illustre bien cette évolution vers des modèles capables de détecter et localiser les tumeurs tout en exploitant des techniques modernes d'attention et de learning transfer.

Cependant, la détection localisée reste plus complexe que la simple classification, car elle nécessite des annotations précises et des données plus variées [3, 8]. Les études récentes montrent que les performances chutent souvent lorsqu'on teste les modèles sur des données provenant d'autres institutions ou acquises avec d'autres protocoles d'imagerie [1, 6]. Cela rappelle qu'un excellent score sur un dataset public ne garantit pas une robustesse clinique réelle.

6 Limites méthodologiques

Malgré les progrès importants, la littérature met en évidence plusieurs limites récurrentes [3, 1]. La première est la taille réduite des bases de données. Beaucoup d'articles utilisent les mêmes ensembles publics, ce qui peut conduire à une surévaluation des performances si les protocoles de validation ne sont pas suffisamment rigoureux [5, 7]. La deuxième limite est la variabilité des modalités d'IRM, des machines et des protocoles d'acquisition, qui affecte la généralisation des modèles [6].

Une autre difficulté concerne la comparaison entre études. Les performances rapportées ne sont pas toujours directement comparables, car les auteurs n'utilisent pas les mêmes jeux de données, ni les mêmes métriques, ni les mêmes stratégies de découpage entraînement/test [3, 8]. Dans plusieurs revues, cette absence d'harmonisation est identifiée comme un frein à la synthèse de l'état de l'art et à la reproductibilité des résultats [1]. Enfin, même lorsque les scores sont élevés, les modèles restent souvent des outils de laboratoire, encore éloignés d'une intégration routinière dans le flux clinique [6, 9].

7 Tendances récentes

Les publications les plus récentes montrent trois tendances fortes [2, 9, 1]. D'abord, l'utilisation combinée de *transfer learning* et d'architectures CNN légères pour améliorer la performance tout en limitant le coût computationnel [4, 2]. Ensuite, le recours à des mécanismes d'attention ou à des architectures hybrides visant à mieux capter les régions pertinentes de l'image [2, 9]. Enfin, l'intérêt croissant pour des approches plus complètes qui ne se limitent plus à la simple classification mais intègrent aussi la localisation et la segmentation [6, 1].

On observe également une volonté croissante de comparer plusieurs architectures sur un même problème afin d'identifier les modèles les plus robustes [3, 8]. Ces travaux comparatifs sont utiles, car ils permettent de dépasser les résultats isolés et de dégager des tendances générales sur les architectures les plus adaptées à la détection de tumeurs cérébrales en IRM [2, 7]. Ils montrent en particulier que les modèles efficaces ne sont pas nécessairement les plus profonds, mais souvent ceux qui équilibrent précision, stabilité et capacité de généralisation [1, 3].

8 Conclusion

En résumé, la littérature montre que les réseaux de neurones convolutifs et le *transfer learning* ont transformé la détection des tumeurs cérébrales à partir d'IRM [3, 1]. Les performances obtenues dans les études récentes sont souvent élevées, ce qui confirme le potentiel du *deep learning* pour l'aide au diagnostic [2, 4, 9]. Néanmoins, la maturité scientifique du domaine est encore limitée par la faiblesse des bases d'entraînement, la difficulté de validation externe et la variabilité des conditions d'imagerie [5, 6, 1].

Références

[1] "Deep Learning for Brain Tumor Detection : Advances and Challenges". In : *npj Precision Oncology* (2024). Étude des limites de validation externe et des défis d'intégration clinique. URL : https://www.nature.com/articles/s41698-024-00789-2.

[2] "Brain Tumor Detection Using Deep Learning and Machine Learning Approaches". In : *Sensors* 25.9 (2025). Inclut notamment une architecture YOLOv7 avec mécanismes d'attention. URL : https://www.mdpi.com/1424-8220/25/9/2746.

[3] "Deep Learning for Brain Tumor Classification and Segmentation : A Review". In : *PMC – PubMed Central* (2023). Revue systématique des approches CNN pour la classification et la segmentation des tumeurs cérébrales. URL : https://pmc.ncbi.nlm.nih.gov/articles/PMC10453020/.

[4] "Brain Tumor Detection Using Machine Learning and Deep Learning Techniques". In : *International Journal of Advanced Trends in Engineering and Management (IJATEM)* (août 2024). Comparaison de plusieurs architectures CNN légères dont MobileNetV3. URL : https://ijatem.com/wp-content/uploads/2024/10/IJATEM24AUG003.pdf.

[5] "A Review of Brain Tumor Detection and Classification Using Machine Learning". In : *PMC – PubMed Central* (2021). Revue des méthodes classiques et premières applications CNN ; souligne les limites de généralisation. URL : https://pmc.ncbi.nlm.nih.gov/articles/PMC8465364/.

[6] *Le deep learning détecte automatiquement six tumeurs cérébrales courantes par IRM*. Thema Radiologie. Article de vulgarisation sur l'application clinique des modèles de détection automatisée. 2024. URL : https://www.thema-radiologie.fr/actualites/3051/le-deep-learning-detecte-automatiquement-six-tumeurs-cerebrales-courantes-par-irm.html.

[7] "Brain Tumor Detection Using Classical Machine Learning Classifiers". In : *International Journal of Nonlinear Analysis and Applications (IJNAA)* (). Approches classiques SVM, k-NN et random forest pour la détection de tumeurs cérébrales. URL : https://ijnaa.semnan.ac.ir/article_6595_8ef9942246cceb3e77e8229b7c5b66ad.pdf.

[8] *Elicit – Systematic review on brain tumor detection with deep learning*. Synthèse bibliographique comparative de plusieurs architectures sur jeux de données publics. 2024. URL : https://elicit.com/review/f672a1b9-4985-45c3-8f3a-d9bf1fd472a3/source/ss-268764685.

[9] "Automated Brain Tumor Detection and Classification Using Deep Learning". In : *PMC – PubMed Central* (2024). Étude portant sur le transfer learning et les architectures hybrides. URL : https://pmc.ncbi.nlm.nih.gov/articles/PMC10973383/.